Анализ потоков данных

Data flow analysis

Синявин А.В.

Бит-векторный анализ

Достигающие определения (reaching definition = RD)


Def: пусть дан некоторый CFG граф


х – некоторая переменная


р – некоторая точка в CFG

- начало некоторого ББ
- конец некоторого ББ
- место между инструкциями

Определение (инструкция) d некоторой переменной х достигает точки p, если ∃ путь от d до p | х не переопределяется вдоль этого пути.







Анализ потоков данных (data-flow analysis = DFA)

Задача вычисления RD — частный случай DFA задачи

Задача определения факта возможности выполнения для каждого пути в общем виде неразрешима.

=>

Будем полагать, что каждый путь может выполнятся.

• С каждой точкой в CFG мы связываем значение потока данных (data-flow value=DFV)

```
Пусть s — инструкция
IN[s] — DFV до инструкции
OUT[s] — DFV после инструкции
```

• Множество значений потока данных – область определения


Ограничения на DFV

- -семантика инструкций
- -основанные на потоке управления

Учёт семантики инструкций

передаточные функции для s

прямое направление



обратное направление

Учёт потока управления

в базовом блоке поток управления простой

$$IN[s_{i+1}] = OUT[s_i]$$
 для $\forall i=1,2,...,n-1$

Поток управления проходит по ББ без ветвлений

=>

Можно рассматривать значения потока при входе в ББ и при выходе из ББ

IN[B] – DFV перед базовым блоком В OUT[B] – DFV после базового блока В

```
Пусть В состоит из s1, s2, ..., sn
=>
IN[B] = IN[s1]
OUT[B] = OUT[sn]
```

Передаточная функция для В

```
f_B_forward(IN[B]) = \\ f_sn_forwrad( ... f_s2_forwrad( f_s1_forward(IN[s1]) ) ... ) ) = \\ f_sn_forwrad ° ... ° f_s1_forwrad(IN[B])
```

Учёт потока управления

в более общем случае

Пусть DFV – информация о множестве констант, которые могут быть присвоены переменным

=> уравнение потока управление $IN[B] = \bigcup_{P-предшественник} OUT[P]$

Консерватизм DFA

- Все алгоритмы DFA дают приближённые решения
- Решение безопасно (консервативно), если программа не меняет результаты вычисления
- Конкретный DFA должен быть консервативным

 $d: u = v \circ p w$

ор – некоторая операция

Инструкция

- генерирует определение d переменной u
- убивает все другие определения переменной и

$$f_d_{out} = gen_d \cup (x - kill_d)$$

Итого

обратная задача

 $IN[B] = f_B_backward(OUT[B])$

OUT[B] = $\Lambda_{S-\text{преемник}} IN[S]$

 Λ - оператор сбора (meet operator)

Пусть базовый блок содержит две инструкции

$$f2(f1(x)) = (gen2 \cup (gen1 - kill2)) \cup (x - (kill1 \cup kill2))$$


Пусть базовый блок содержит N инструкций

```
f1(x) = gen1 \cup (x - kill1) для первой инструкции
f2(x) = gen2 \cup (x - kill2) для второй инструкции
fN(x) = genN \cup (x - killN) для N-ой инструкции
fB(x) = genB \cup (x - killB), где
     killB = kill1 ∪ kill2 ∪ kill3 ∪ ... ∪ killN
    genB = genN U
                     (gen[N-1] - killN) \cup
                     (gen[N-2] - kill[N-1] - kill[N]) \cup
                     (gen1 - kill2 - kill3 - ... - killN)
```

 genB содержит все определения, которые видны сразу после блока

• killB – простое объединение kill для всех инструкций

$$fB(x) = genB \cup (x - killB)$$



Вычисление RD (уравнение потока управления)

• Определение достигает точки р, если ∃ путь, вдоль которого точка р может быть достигнута

OUT[P] ⊆ IN[B], $P - \forall$ предшественник B

 Определение не может достигнуть точки р, если ∄ пути до р

T.o.,

$$IN[B] = \bigcup_{P-предшественник B} OUT[P]$$

Вычисление RD (система уравнений)

Введём два пустых ББ в CFG. Входной и выходной.

OUT[вход] =
$$\emptyset$$
OUT[В] = genB \cup (IN[В] - killВ)
IN[В] = $\bigcup_{P-\text{предшественник } B}$ OUT[P]

Вычисление RD (решение системы уравнений)

```
Алгоритм решение системы уравнений для RD
Bход: CFG
Выход: DFV IN[B], OUT[B] для всех ББ
Метод:
"OUT[Bxoд] = \emptyset;";
for ( "каждый ББ В" ) "OUT[В] = Ø;";
while ("внесены изменения в OUT")
   for ( "каждый ББ В" )
       "IN[B] = \bigcup_{P-\text{предшественник } B} OUT[P]";
       "OUT[B] = genB \cup (IN[B] - killB)";
```

Консерватизм решения задачи поиска RD

Реальность:


мн-во достигающих определений в р { d1, d2 }






Наш алгоритм в этом смысле безопасен

Анализ активных переменных live-variable (LV) analysis



Def: Переменная X активна (жива), если З путь в CFG от р до некоторой точки, где используется значение переменной X



Def: В противном случае переменная X мертва

Анализ активных переменных

Мотивация:

Понятие LV важно для распределения регистров.

Пусть x1 и x2 активны в р одновременно, тогда x1 и x2 не могут быть размещены на одном аппаратном регистре.

Анализ активных переменных

IN[B] и OUT[B] – мн-ва LV, где В – базовый блок

defB — мн-ва переменных, определённых в В до любых их использований в В (если есть такие использования)

useB — мн-ва переменных, значения которых могут использоваться до любых определений в В (если есть такие определения)

Анализ активных переменных (система уравнений)

LV при выходе из программы нет

$$IN[выход] = \emptyset$$

Х активен при входе в В

- Х используется до возможного переопределения в В
- Х активен на выходе В и не переопределён в В

$$IN[B] = useB U (OUT[B] - defB)$$


X активен при выходе из B <=> X активен при входе в один из преемников

OUT[B] =
$$\bigcup_{S-\text{преемник } B} IN[S]$$

Анализ активных переменных (решение системы уравнений)

```
Алгоритм решение системы уравнений для LV
Вход: CFG
Выход: DFV IN[B], OUT[B] для всех ББ
Метод:
"IN[Выход] = \emptyset;";
for ( "каждый ББ В" ) "IN[В] = Ø;";
while ("внесены изменения в IN")
{
   for ( "каждый ББ В" )
        "OUT[B] = \bigcup_{S-\text{преемник }B} IN[S]";
        "IN[B] = useB \cup (OUT[B] - defB)";
```

Анализ доступных выражений (available expression =AE analysis)



Def: выражение x+y доступно в точке р, если ∀ путь от входного ББ до р вычисляет х+у и после последнего вычисления до достижения р нет присваиваний Х и Ү

Анализ доступных выражений

Мотивация:

Понятие АЕ удобно при поиске общих подвыражений

Анализ доступных выражений

U – мно-во всех выражений

IN[B] — мно-во АЕ на входе в В OUT[B] — мно-во АЕ на выходе в В

IN[B], $OUT[B] \subseteq U$

e_kill[B] — мн-во AE, убиваемых (х.б. один аргумент переопределяется) в В

e_gen[B] – мн-во AE, генерируемых (выражение вычисляется и далее в B не убиваются) В

Анализ доступных выражений (система уравнений)

На входе АЕ нет

$$OUT[вход] = \emptyset$$

АЕ на выходе из В есть, если

- генерируется в В
- АЕ есть на входе в В и не убивается в В

$$OUT[B]=e_gen[B] \cup (IN[B] - e_kill[B])$$

АЕ есть на входе в В, если АЕ есть в конце всех предшественников

$$IN[B] = \bigcap_{P-\text{предшественник}} OUT[P]$$

Анализ доступных выражений (решение системы уравнений)

```
Алгоритм: решение системы уравнений для АЕ
Вход: CFG
Выход: DFV IN[B], OUT[B] для всех ББ
Метод:
"OUT[Bxoд] = \emptyset;";
for ( "каждый ББ В, отличный от входного" ) "OUT[B] = U";
while ("внесены изменения в OUT")
   for ( "каждый ББ В , отличный от входного" )
          "IN[B] = \bigcap_{P-\text{предшественник}} OUT[P]";
          "OUT[B]=e gen[B] \cup (IN[B] – e kill[B])";
```

Формализация DFA

Def: Полурешётка — множество (V, Λ) | \forall x, y, z \in V

- $x \wedge x = x$ (идемпотентность)
- $x \wedge y = y \wedge x$ (коммутативность)
- $x \wedge (y \wedge z) = (x \wedge y) \wedge z$

л - оператор сбора (meet)

Формализация DFA

Def: (V, Λ) — полурешётка. Верхний элемент $T \mid \forall$ $x \in V$

$$T \wedge x = x$$

Def: (V, Λ) — полурешётка. Нижний элемент $\bot \mid \forall$ $x \in V$

$$\bot \land x = \bot$$

Частичный порядок

Def: Мн-во V — частично упорядоченное мн-во, если ∃ отношение ≤ |

$$\forall x, y, z \in V$$
, верно

- $x \le x$ (рефлексивность)
- Если $x \le y$ и $y \le x$, то x = y (антисимметричность)
- Если $x \le y$ и $y \le z$, то $x \le z$ (транзитивность)

Частичный порядок в полурешётке

В полурешётке можно определить частичный порядок

$$x \le y \iff x \land y = x$$

Частичный порядок в полурешётке

Области определения , которые были в DFA (RD, LV, AE) , - полурешётки

Операторы ∩, U - операторы сбора

$$IN[B] = \bigcup_{P-предшественник B} OUT[P]$$

IN[B] =
$$\bigcap_{P-\text{предшественник } B} OUT[P]$$

Наибольшая нижняя граница

Def: Наибольшая нижняя граница (greatest lower bound - GLB)

Пусть (V, Λ) — полурешётка g - GLB для $x, y \in V$, если

- g ≤ x
- g ≤ y
- $\forall z \in V \mid z \leq x \ u \ z \leq y \Longrightarrow z \leq g$

Наибольшая нижняя граница

Легко доказать, что


 \forall x, y \in V (полурешётка)


х ∧ у является GLB для элементов х, у

Диаграммы решёток

Пример для RD

Пусть даны определения d1, d2, d3





Def: восходящая цепочка — последовательность вида

Def: высота полурешётки - наибольшее кол-во отношений < в восходящей цепочке

Обобщённый алгоритм (прямая версия)

```
Алгоритм: решение прямой задачи DFA
Вход: CFG
Выход: DFV IN[B], OUT[B] для всех ББ
Метод:
"OUT[Bxoд] = v0";
for ( "каждый ББ В, отличный от входного" ) "OUT[B] = T";
while ("внесены изменения в OUT")
   for ( "каждый ББ В , отличный от входного" )
         "IN[B] = \Lambda_{P-\text{предшественник}} OUT[P]";
         "OUT[B]= f_R(IN[B])";
```

Обобщённый алгоритм (обратная версия)

```
Алгоритм: решение обратной задачи DFA
Вход: CFG
Выход: DFV IN[B], OUT[B] для всех ББ
Метод:
"[N[Bыход] = v0"];
for ( "каждый ББ В, отличный от выходного" ) "IN[B] = Т";
while ("внесены изменения в IN")
   for ( "каждый ББ В , отличный от выходного" )
         "OUT[B] = \Lambda_{S-\text{преемник}} IN[S]";
         "IN[B]= f_R(OUT[B])";
```

Static Single Assignment

Понятие и построение SSA

Понятие SSA x ← 5 $x_2 \leftarrow x_1-3$ $x_2 < 3?$ $x \leftarrow x-3$ x<3? $y_2 \leftarrow x_2 - 3$ $y_1 \leftarrow x_2 * 2 \\ w_1 \leftarrow y_1$ $y \leftarrow x - 3$ $y_3 \leftarrow \phi(y_1, y_2)$ $z_1 \leftarrow x_2 + y_3$

Каждая переменная имеет только одно присваивание

Зачем?

В терминах SSA описываются многие оптимизирующие алгоритмы

Алгоритм построения

Делится на две части:

- размещение ф-функций
- переименование переменных (определение версий переменных)

Def: Соединение некоторого подмножества $S \subseteq V$ множества вершин


$$J(S) = \{x | \exists p_1, p_2 \in S, \ p_1 \neq p_2, \ x \in V \}$$
 \exists непустые непересекающиеся пути из p_1 в x и из p_2 в $x\}$

Def: Итерированное соединение $J^+(S)$ некоторого подмножества $S \subseteq V$ множества вершин

$$J_1 = J(S)$$
 $J_2 = J(S \cup J_1)$
 $J_3 = J(S \cup J_2)$ Процесс делается до тех пор, пока Jk не перестанет меняться


J(S)

Волнистые линии – непустые непересекающиеся ПУТИ



размещаем Ф-функцию

 $MyVar = \Phi(...)$



Ф-функцию

MyVar = $\Phi(...)$

ПУТИ

S –вершины, в которых делается присвоение переменной MyVar

 $J^{+}(S)$ - где следует расположить ϕ -функции для переменной MyVar

Непосредственное вычисление $J^+(S)$ - слишком дорого

Оказывается $J^+(S)$ можно вычислить через доминаторы


Def: Dominance frontier DF(x) для одной вершины
Пусть дан некий CFG
x — вершина CFG графа


$$DF(x) = \{y | \exists p \in Pred(y) \\ x \ dom \ p \ \&\& \ x \ sdom \ y\}$$

x sdom y означает x dom y и $x \neq y$

=>

x s dom y означает x dom y или x = y





Узлы 4, 13, 12 представляют собой блоки, над которыми блок 5 не доминирует и они такие встречаются первыми на путях из 5.

Т.е. это граница, где исчезает доминирование блока 5.

 $DF(5) = \{4, 5, 12, 13\}$

Узел 5 – особый случай

Def: Dominance frontier DF(S) для нескольких вершин

Пусть дан некий CFG, V — множество вершин $S \subseteq V$

$$DF(S) = \bigcup_{x \in S} DF(x)$$

Def: Итерированное dominance frontier $DF^+(S)$ для нескольких вершин

Пусть дан некий CFG, V — множество вершин $S \subseteq V$

$$DF_1 = DF(S)$$

 $DF_2 = DF(S \cup DF_1)$
 $DF_3 = DF(S \cup DF_2)$

• • •

$$DF_{i+1} = DF(S \cup DF_i)$$

Процесс делается до тех пор, пока DFk не перестанет меняться

Оказывается, что

Теорема #1:

$$DF^+(S) = J^+(S)$$

Т.о., для размещения ф-функций нам нужно

- вычислить DF(S)
- "проитерировать" вычисленное выше множество

Прямое вычисление DF(x) имеет квадратичную сложность от числа вершин

Теорема #2: Children в доминаторном дереве $DF(x) = DF_{local}(x) \ \cup \ \cup_{z \in children(x)} DF_{up}(z)$

 $DF_{local}(x) = \{y \mid y \in Succ(x) \text{ и x dom y}\}$ $DF_{up}(z) = \{y \mid y \in DF(z) \text{ и idom(z) dom y}\}$

Алгоритм построения (размещение ф-функций) Алгоритм построения DF для вершины

```
Вход: CFG
Выход: для каждой вершины готовый DF(x)
Метод:
list<vertex> post_order;
map<vertex, set<vertex>> DF;
foreach(vertex x in post_order)
   DF[x] = new set<vertex>;
   foreach(vertex y in succ(x))
      if ( idom(y) != x ) DF[x] += y; /* local */
   foreach(vertex z in children(x))
      foreach(vertex y in DF(z))
         if ( idom(y) != x ) DF(x) += y; /* up */
return DF;
```

```
Алгоритм построения DF для мн-ва вершин
Вход: CFG, S \subseteq V
Выход: DF(S)
Meтод: DF_Set(S)
                          /* результат */
set<vertex> res;
foreach ( vertex v in S )
   res += DF(v);
return res;
```

```
Алгоритм построения DF^+(S) для мн-ва вершин
```

Вход: CFG, $S \subseteq V$


Выход: DF(S)


Mетод: DFP_Set(S)

```
set<vertex> res;
set<vertex> DFP;
bool change = true;
DFP = DF Set(S);
do
   change = false;
   DFP = DF Set(S+DFP);
   if ( DFP != res )
        DFP = D;
        change = true;
while( change );
return res;
```

Св-во SSA-формы

Определения переменных доминируют над их использованиями в обычных инструкциях (не ф-функции)






SSA уже здесь построено

Если A dom B,

то в В можно попасть, минуя присваивание



Алгоритм: переименование переменной р Вход: CFG, вставлены ф-функции для переменной р Выход: CFG с переименованными переменными Метод: RenameVar(p)

int counter=0;
list<int> stack;
Traverse(entry);


/* продолжение на след. слайде */

```
void Traverse(vertex v)
 foreach(stmt s in v.stmts)
                                                vertex - базовый блок
                                                v.stmts – инструкции в ББ
   if (!s.is phi)
                                                s.is phi – True, если инструкция
     является Ф-функцией
                                                s.rhs – правая часть присваивания
                                                s.lhs – левая часть присваивания
   заменить р на рі в s.lhs, где i=counter;
   stack.push(i);
   counter = i + 1;
 } /* first loop */
 foreach(vertex v1 in Succ(v)) /* - последователи в CFG */
    int j = WhichPred(v1, v); /* порядковый номер v в
                             массиве предшественников v1 */
    foreach(stmt phi in v1.phis)
     заменить j-ый операнд р в phi.rhs на pi, где i=stack.top();
 }/* second loop */
 /* продолжение на следующем слайде */
```

```
foreach(vertex v1 in Child(v)) /*
                               child – последователи в
                               дереве доминаторов */
   Traverse(v1); /* рекурсивный вызов */
 foreach(stmt s in v.stmts)
   if ( в s.lhs переменная р любой версии )
     stack.pop();
}/* конец Traverse(v) */
```

Алгоритм построения (определение версий переменных)

int j = WhichPred(v1, v); /* порядковый номер v в массиве предшественников v1 */



Список литературы

- Компиляторы. Принципы, технологии и инструментарий. 2-е изд. А. Ахо (бит-векторный анализ)
- Компиляторы. Принципы, технологии и инструментарий. 1-е изд. А. Ахо (бит-векторный анализ)
- Advanced compiler design & implementation. S. Muchnik (SSA)
- Efficiently Computing Static Single Assignment Form and the Control Dependence Graph. R. Cytron

Дополнение / факультатив

на зачёте спрашиваться НЕ будет

Передаточные функции

Def: структура DFA (D, F, V, Λ) монотонна, если

$$\forall f \in F$$
 и $\forall x, y \in V \mid x \leq y$

$$=>$$

$$f(x) \leq f(y)$$

Передаточные функции

мн-во передаточных функций F f:V -> V обладает св-вами

- F содержит тождественную функцию I |
 ∀ x ∈ V I(x)=x
- Г замкнуто относительно композиции функций

Легко видеть, что передаточные функции в DFA (RD, LV, AE) удовлетворяют этим условиям

Передаточные функции

Def: структура DFA (D, F, V, Λ) дистрибутивна, если

$$\forall x, y \in V$$

$$=>$$

$$f(x \land y) = f(x) \land f(y)$$

Обобщённый алгоритм (св-ва)

Если алгоритм сходится, то получающийся результат является решением уравнений потоков данных.

□ Если при выходе из некоторой итерации цикла while уравнения не удовлетворяются, то в OUT (IN) будет внесено изменение => потребуется вернуться в цикл while ▷

Обобщённый алгоритм (св-ва)

Если структура монотонна, то решение (MFP = Maximum Fixed Point) обладает тем св-ом, что в любом другом решении значения IN/OUT не превышают соответствующих значений MFP.

 \triangleleft

1) Докажем по индукции, что значения IN[B] и OUT[B] могут только не увеличиваться

Базис: Тривиален, т.к. все начальные значения устанавливаются в Т

Индукция: Пусть $out[P]^k \leqslant out[P]^{k-1}$

$$IN[B] = \land_{P-\text{предшественник }B} OUT[P]$$
 $OUT[P]^k \leqslant OUT[P]^{k-1} => IN[B]^{k+1} \leqslant IN[B]^k$. (В СИЛУ СВ-В оператора сбора)

2) Оператор сбора возвращают GLB своих аргументов. Передаточные функции возвращают только решения, согласующиеся с самим блоком. => результат алгоритма должен быть не меньше любого другого решения ур-ий

Обобщённый алгоритм (св-ва)

Если полурешётка структуры монотонна и имеет конечную высоту, то алгоритм сходится.

4

Значения IN[B] / OUT[B] не увеличивается при каждом изменении. Алгоритм завершает свою работу при отсутствии изменений. =>

Алгоритм сойдётся не позже чем N*M итераций N – кол-во узлов графа, M – высота полурешётки



Идеальное решение

Рассмотрим возможный путь

("возможный" – означает, что некоторое вычисление программы следует по этому пути)

$$P = \mathbf{B} \mathbf{XO} \mathbf{J} \rightarrow B_1 \rightarrow B_2 \rightarrow \cdots \rightarrow B_{k-1} \rightarrow B_k$$

передаточная функция для этого пути

$$f_P \qquad f_{B_1}, f_{B_2}, \dots, f_{B_{k-1}}$$

Определим идеальное решение как

IDEAL
$$[B] = \bigwedge_{P$$
—возможный путь от входа к B

Идеальное решение (св-ва)

- любое решение, большее, чем IDEAL не верен
- любое решение, меньшее или равное, консервативно (безопасно)
- значение, более близкое к идеальному, является более точным

Решение сбором по путям (МОР - решение)

МОР
$$[B] = \bigwedge_{P$$
-путь от входа к B $f_P(v_{\text{ВХОД}})$

Здесь включаются все пути в графе до вершины В даже те, которые реально не могут быть пройдены в процессе вычисления.

Очевидно, что

$$MOP[B] \leq IDEAL[B]$$

MFP и MOP-решения

MOP-решение в общем случае получить нельзя из-за циклов

Обобщённый алгоритм посещает ББ не обязательно в порядке их выполнения


Как соотносятся МГР и МОР решения?

MFP и MOP-решения

Оказывается можно показать, что

 \boldsymbol{B}_2

 $MFP \leq MOP$



Для МОР-решения

МОР
$$[B_4] = ((f_{B_3} \circ f_{B_1}) \wedge (f_{B_3} \circ f_{B_2})) (v_{\text{ВХОД}})$$

Для обобщённого алгоритма

IN
$$[B_4] = f_{B_3} ((f_{B_1} (v_{\text{ВХОД}}) \wedge f_{B_2} (v_{\text{ВХОД}})))$$

Структура монотонна => $IN[B_4] \leq MOP[B_4]$

Итого

```
MOP ≤ IDEAL,

MFP ≤ MOP,

=>

MFP ≤ IDEAL.
```

Результат работы обобщённого алгоритма консервативен (т.е. безопасен)